

Modèle De survie de cox

Jolémon GLODJO

March 2026

1 Introduction

L'analyse de (la) survie est une branche des statistiques qui cherche à modéliser le temps restant avant la mort pour des organismes biologiques (l'espérance de vie) ou le temps restant avant l'échec ou la panne dans les systèmes artificiels, ce que l'on représente graphiquement sous la forme d'une courbe de survie. Le modèle de survie de Cox, ou régression de Cox, est un modèle semi-paramétrique utilisé pour analyser le temps jusqu'à un événement, souvent en lien avec la survie des individus. L'utilisation du modèle s'est étendue à d'autres situations, l'événement peut donc être de quelconque nature : il peut s'agir de la récurrence d'une maladie, ou à l'inverse d'une guérison. D'un point de vue statistique, la nature de l'événement n'est bien sûr pas importante, il s'agira alors d'interpréter les coefficients en conséquence.

1.1 Présentation du modèle de cox

1.1.1 Principe du modèle de survie

Formulation générale La fonction de survie (« Survival function »), notée S par convention, est définie par :

$S(t) = \mathbb{P}(T > t)$ où :

- t est la variable temps, T est une variable aléatoire symbolisant le moment du décès, et
- $\mathbb{P}$
- $\mathbb{P}$ est la fonction probabilité.

La fonction de survie est égale à la probabilité que le décès intervienne après un temps t donné. La fonction de distribution de longévité, notée F , est définie en complément de la fonction de survie,

$$F(t) = \mathbb{P}(T \leq t) = 1 - S(t)$$

1.2 Modèle de cox

le modèle de Cox exprime la fonction de risque instantané de décès (on peut aussi trouver les appellations suivantes : fonction de risque, taux de panne, taux de fiabilité, force de mortalité, taux de risque...) en fonction du temps t et des covariables $X_1, \dots, X_n$

$$\lambda(t, X_1, \dots, X_n) = \lambda_0(t) \exp(\sum_{i=1}^n \beta_i X_i)$$

Avec :

- $\lambda(t, X_1, \dots, X_n)$ correspond au risque instantané de décès à l'instant t sachant qu'il est vivant juste avant t .
- λ_0 la probabilité ou risque de base. Il correspond au risque instantané de décès lorsque toutes les covariables sont nulles. $h_0(t) = h(t | Z_1 = 0, \dots, Z_p = 0)$ (Attention : le risque de base ne représente pas le risque instantané en l'absence de covariables !)
- β_i est un paramètre inconnu de dimension p . Ce paramètre ne dépend pas du temps t . Il **représente l'effet des covariables sur le risque instantané**.
- il représente le risque relatif

2 Avantages du Modèle de Cox

- **Flexibilité** : Le modèle ne fait aucune hypothèse sur la forme de la fonction de risque de base, ce qui le rend semi-paramétrique. Cela permet d'analyser des données avec des distributions inconnues.
- **Gestion des Données Censurées** : Il est capable de gérer les données censurées, ce qui est courant dans les études de survie où tous les sujets ne sont pas suivis jusqu'à l'événement.
- **Interprétation des Coefficients** : Les coefficients estimés mesurent l'effet des covariables sur le risque de survenue de l'événement, permettant une interprétation claire des résultats

3 Hypothèse

Deux grandes hypothèses sont présentes au niveau du modèle de cox Nous avons les hypothèses du :

- Taux ou risques proportionnels
- Linéarité ou log-linéarité

Hypothèse des risques proportionnels Le rapport des risques instantanés ("hazard rate" en anglais) de deux patients est indépendant du temps. Pour chaque covariable, on teste alors si son effet est indépendant du temps. Cette condition doit être satisfaite, ce qui signifie qu'il peut être bénéfique, nocif ou simplement nul. Il s'agit d'une hypothèse forte du modèle de Cox, il faut donc

au préalable vérifier que celle-ci est satisfaite. Plusieurs test statistiques nous permettent de vérifier cette hypothèse :

1. Test graphiques(mais pas certains....juste des suggestions)
2. Test statistiques :
 - (a) Test des **résidus de Schoenfeld**
 - (b) n

Hypothèse de linéarité $\log(\lambda(t|X_i1, ..., X_ip)) = \log(\lambda_0(t)) + \beta_0 X_i$. Le logarithme du risque instantané est une fonction linéaire des Z_{ij} . C'est l'hypothèse de log-linéarité.

4 Estimations des coefficients

L'estimation des paramètres du modèle de cox se fait par la méthode du maximum de vraisemblance

On considère le modèle à risques proportionnels :

$$\lambda(t | X_i) = \lambda_0(t) \exp(\beta^T X_i) \quad (1)$$

où :

- $\lambda_0(t)$ est le risque de base (inconnu),
- β est le vecteur des paramètres,
- X_i est le vecteur de covariables.

Au lieu de construire la vraisemblance complète, on conditionne sur les instants où les événements se produisent.

On note les temps d'événements :

$$t_{(1)} < t_{(2)} < \dots < t_{(k)} \quad (2)$$

À chaque instant $t_{(j)}$, on définit l'ensemble à risque :

$$R(t_{(j)}) = \{l | T_l \geq t_{(j)}\} \quad (3)$$

Pour un individu $i \in R(t_{(j)})$, la probabilité qu'il soit celui qui subit l'événement à $t_{(j)}$ est :

$$P(i \text{ échoue à } t_{(j)} | R(t_{(j)})) = \frac{\lambda(t_{(j)} | X_i)}{\sum_{l \in R(t_{(j)})} \lambda(t_{(j)} | X_l)} \quad (4)$$

En remplaçant $\lambda(t | X)$:

$$= \frac{\lambda_0(t_{(j)}) \exp(\beta^T X_i)}{\sum_{l \in R(t_{(j)})} \lambda_0(t_{(j)}) \exp(\beta^T X_l)} \quad (5)$$

On simplifie par $\lambda_0(t_{(j)})$:

$$= \frac{\exp(\beta^T X_i)}{\sum_{l \in R(t_{(j)})} \exp(\beta^T X_l)} \quad (6)$$

En multipliant sur tous les événements :

$$L(\beta) = \prod_{j=1}^k \frac{\exp(\beta^T X_{(j)})}{\sum_{l \in R(t_{(j)})} \exp(\beta^T X_l)} \quad (7)$$

$$L(\beta) = \prod_{i=1}^m \frac{\exp(\beta^T \Sigma_{k \in D_i} X_k)}{[\sum_{l \in R_i} \exp(\beta^T X_l)]^{d_i}}$$

On fait les hypothèses :

- **Censure indépendante** de la variable d'intérêt conditionnellement aux covariables : $\sim T$ est indépendant de C conditionnellement à Z .
- **Censure non-informative** : la loi de C ne dépend pas des paramètres du modèle (ni de $1, \dots, p$ ni de h_0)

Forme générale avec censure

On peut écrire :

$$L(\beta) = \prod_{i=1}^n \left[\frac{\exp(\beta^T X_i)}{\sum_{l \in R(T_i)} \exp(\beta^T X_l)} \right]^{\delta_i} \quad (8)$$

Log-vraisemblance partielle

On prend le logarithme :

$$\ell(\beta) = \log L(\beta) \quad (9)$$

$$\ell(\beta) = \sum_{i=1}^n \delta_i \log \left(\frac{\exp(\beta^T X_i)}{\sum_{l \in R(T_i)} \exp(\beta^T X_l)} \right) \quad (10)$$

or

$$\log \left(\frac{a}{b} \right) = \log a - \log b \quad (11)$$

Donc :

$$\ell(\beta) = \sum_{i=1}^n \delta_i \left[\log \exp(\beta^T X_i) - \log \left(\sum_{l \in R(T_i)} \exp(\beta^T X_l) \right) \right] \quad (12)$$

Simplification finale

$$\log \exp(\beta^T X_i) = \beta^T X_i \quad (13)$$

Donc :

$$\boxed{\ell(\beta) = \sum_{i=1}^n \delta_i \left[\beta^T X_i - \log \left(\sum_{l \in R(T_i)} \exp(\beta^T X_l) \right) \right]} \quad (14)$$

5 Interprétation des coefficients

Les coefficients du modèle de Cox s'interprètent **exclusivement via leur exponentielle** : $\exp(\beta)$, appelée le **rapport de risques** (hazard ratio, HR).

- Si $\beta_1 > 0$ d X_i 1
- Si $\beta_1 < 0$, $\exp(\beta) < 1$ et le risque que l'évènement d'intérêt se produise augmente quand X_i 1 diminue (et diminue quand X_i 1 augmente).
- Si $\beta_1 = 0$, $\exp(\beta_1) = 1$ et la variable X_i 1 n'a pas d'impact sur le risque instantané

6 Applications

Nous prendrons un cas pratique pour dérouler le modèle de cox afin de montrer son apport et ses ressortissants

7 Références

1. **(en)** D. Schoenfeld, « Partial Residuals for The Proportionnal Hazards Regression Model », *Biometrika*, vol. 69, 1982, p. 239-241
2. **(en)** D.R. Cox, « Partial Likelihood », *Biometrika*, vol. 62, 1975, p. 269-276
3. **(en)** Z. Ying, L.J. Wei, « The Kaplan-Meier Estimate for Dependent Failure Time Observations », *Journal of Multivariate Analysis*, vol. 50, 1994, p. 17-29
4. **(en)** D.Y. Lin, « Cox Regression Analysis of Multivariate Failure Time Data : The Marginal Approach », *Statistics In Medicine*, vol. 13, 1994, p. 2233-2247

5. **(en)** C.F. Spiekerman, D.Y. Lin, « Marginal Regression Models for Multivariate Failure Time Data », *Journal of the American Statistical Association*, vol. 93, 1998, p. 1164-1175